

Exploitation de prédicteurs qualitatifs

L'introduction dans un modèle à terme constant de prédicteurs qualitatifs (facteurs) pose un problème technique, la design matrix T n'étant alors plus de plein rang. Les vecteurs colonnes de T étant liés, ils ne constituent plus une base du sous-espace Q .

Le vecteur Y^* , projeté orthogonal de Y sur Q existe et est unique mais son expression en fonction des vecteurs colonnes de T ne l'est plus (on peut en effet désormais définir plusieurs jeux de paramètres β_k satisfaisant au problème) : **le modèle n'est alors pas identifiable.**

Imposer une contrainte sur les paramètres de chaque prédicteur qualitatif va permettre de fixer un jeu de coefficients et d'identifier au final le modèle.

Le choix de la contrainte n'a aucun impact sur le modèle et ses prévisions (Y^* est unique) mais il en aura un sur l'interprétation des paramètres effectivement estimés par le logiciel.

Pour simplifier, un seul prédicteur qualitatif Z à 2 modalités, nommées A et B, est ici considéré dans la suite (les explications sont généralisables aux prédicteurs à plus de 2 modalités et à l'exploitation de plusieurs prédicteurs qualitatifs dans le même modèle).

L'impact du prédicteur Z sur le prédicteand est modélisé en introduisant dans le modèle un paramètre par modalité, représentant l'effet moyen de la modalité ; soit ici α_A et α_B ces 2 paramètres.

$$Y_i = \beta_0 + \sum_{j=1}^q \beta_j X_{ij} + \alpha_i + e_i$$

avec $\alpha_i = \alpha_A$ ou α_B selon l'occurrence de la modalité.

a)

Contrainte notée « $\alpha_A=0$ » dans la littérature : elle signifie que la modalité A de la variable Z est alors prise comme référence, **c'est la contrainte imposée par défaut par les logiciels de statistiques.**

Le modèle est reconsidéré ainsi : $Y_i = (\beta_0 + \alpha_A) + \sum_{j=1}^q \beta_j X_{ij} + (\alpha_i - \alpha_A) + e_i$

$$Y_i = \beta_0' + \sum_{j=1}^q \beta_j X_{ij} + \alpha_i' + e_i$$

avec $\beta_0' = \beta_0 + \alpha_A$ et $\alpha_i' = \alpha_i - \alpha_A$, on a alors :

$\alpha_A' = \alpha_A - \alpha_A = 0$ et $\alpha_B' = \alpha_B - \alpha_A =$ **effet différentiel** de la modalité B par rapport à la modalité A.

Il n'y a plus ainsi qu'un paramètre à estimer α_B' concernant la variable Z , la matrice T perdant une dimension est de nouveau de plein rang et les calculs réalisables. Mais les paramètres estimés ne sont pas les paramètres initiaux du modèle, il faut donc faire très attention lors des interprétations.

Avec cette contrainte, les paramètres estimés sont les effets différentiels de chaque modalité par rapport à celle qui a été choisie comme référence.

b)

On peut utiliser d'autres contraintes, comme par exemple la contrainte notée « $\alpha_A + \alpha_B = 0$ », la référence prise étant alors la demi-somme des impacts moyens des 2 modalités :

$$Y_i = \left(\beta_0 + \frac{\alpha_A + \alpha_B}{2}\right) + \sum_{j=1}^q \beta_j X_{ij} + \left(\alpha_i - \frac{\alpha_A + \alpha_B}{2}\right) + e_i$$

$$Y_i = \beta_0' + \sum_{j=1}^q \beta_j X_{ij} + \alpha_i' + e_i$$

avec $\beta_0' = \beta_0 + (\alpha_A + \alpha_B)/2$ et $\alpha_i' = \alpha_i - (\alpha_A + \alpha_B)/2$, on a alors :

$$\alpha_A' = (\alpha_A - \alpha_B)/2 \quad \text{et} \quad \alpha_B' = (\alpha_B - \alpha_A)/2 = -\alpha_A'$$

Là encore, un seul paramètre est à estimer, le second étant son opposé. La matrice T perd une dimension et les calculs peuvent être menés.