

Test de significativité d'un coefficient du modèle

Pour chaque paramètre β_k du modèle avec $k=1,\dots,q$ on teste au niveau α l'hypothèse nulle

$H_0 : \beta_k = 0$ » contre l'hypothèse alternative $H_1 : \beta_k \neq 0$ » (test bilatéral).

Sous H_0 , la statistique $\frac{\hat{\beta}_k}{\hat{\sigma}_k}$ suit la loi de Student à $n-q$ degrés de liberté, avec :

$$\hat{\sigma}_k = \sqrt{\hat{\sigma}^2 ({}^tTT)^{-1}_{kk}} = \sqrt{\frac{\|Y - T\hat{\beta}\|^2}{n-q} ({}^tTT)^{-1}_{kk}}$$

Règle de décision en exploitant la p-value du test :

Si $p_value < \alpha$: rejet de H_0 au niveau α (on considère β_k non nul $\rightarrow$ prédicteur associé à conserver)

Si $p_value > \alpha$: les données ne permettent pas le rejet de H_0 au niveau α (β_k peut être nul et le prédicteur a alors peu d'intérêt, car ayant une influence jugée négligeable).

Le logiciel R fournit un tableau résumant le modèle estimé, le nombre de lignes correspondant à la dimension du modèle (dimension du vecteur β). Chaque ligne rassemble les résultats relatifs à l'estimation de chaque composante de β , le nom du prédicteur associé à chaque paramètre est mentionné en début de ligne (*intercept* pour le terme constant β_0).

La colonne *Estimate* contient les estimations des q composantes β_k de β .

La colonne *Std.Error* contient les écarts-types estimés des estimateurs des paramètres β_k .

La colonne *t.value* contient les valeurs prises par les statistiques des tests sur votre échantillon.

La colonne *Pr(>|t|)* contient les p-values des tests de Student bilatéraux réalisés.

On a donc, d'après le cours : **$t.value = Estimate / Std.Error$**

(= variable aléatoire qui suit la loi de Student à $(n-q)$ ddl sous $H_0 : \beta_k = 0$ »)

Preuve :

Définition d'une variable de Student :

Soit U une variable normale centrée réduite et V une variable du Chi-deux à p degrés de liberté, U et V étant indépendantes.

Alors la variable $\frac{U}{\sqrt{\frac{V}{p}}}$ suit une loi de Student à n degrés de liberté.

D'après le Théorème de Cochran vu en 1^{ère} année, on sait que la variable $\frac{\|Y - T\hat{\beta}\|^2}{\sigma^2} = \frac{\|\varepsilon\|^2}{\sigma^2} = \frac{\|\Pi_{Q^\perp} Y\|^2}{\sigma^2}$

suit une loi du Chi-deux à n-q degrés de liberté ,

et que $\Pi_Q Y$ et $\Pi_{Q^\perp} Y$ sont des vecteurs aléatoires gaussiens indépendants.

$\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 ({}^t T T)^{-1}_{kk}}}$ suit une loi normale centrée réduite. En exploitant l'estimateur de σ^2 on obtient :

$$\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 ({}^t T T)^{-1}_{kk}}} = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\frac{\|Y - T\hat{\beta}\|^2}{n-q} ({}^t T T)^{-1}_{kk}}} = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\frac{\|Y - T\hat{\beta}\|^2}{n-q} \frac{\sigma^2}{\sigma^2} ({}^t T T)^{-1}_{kk}}} = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\frac{\|Y - T\hat{\beta}\|^2 / \sigma^2}{n-q} \sigma^2 ({}^t T T)^{-1}_{kk}}} = \frac{U}{\sqrt{\frac{V}{n-q}}}$$

avec $U = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 ({}^t T T)^{-1}_{kk}}}$ variable normale centrée réduite,

et $V = \frac{\|Y - T\hat{\beta}\|^2}{\sigma^2} = \frac{{}^t Y \Pi_{Q^\perp} Y}{\sigma^2}$ variable du Chi-deux à n-q degrés de liberté.

U et V sont indépendantes car V est fonction de $\Pi_{Q^\perp} Y$

et U fonction de $\Pi_Q Y$ car on a en effet : $\hat{\beta} = ({}^t T T)^{-1} {}^t T \Pi_Q Y$,

$\frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2 ({}^t T T)^{-1}_{kk}}}$ suit donc la loi de Student à n-q degrés de liberté.