

APPRENTISSAGE SUPERVISE

Modèle linéaire gaussien & Introduction au modèle linéaire généralisé

HPC – Big Data / Statistiques 2
Mars 2026

Bibliographie

- **Statistique : la théorie et ses applications, Lejeune, Springer**
- **Régression avec R, Cornillon & al., Springer**
- **An introduction to statistical learning, James & al., Springer (→ moodle)**

Pour aller plus loin :

- An introduction to generalized linear models, Dobson & Barnett, CRC Press
- An R companion to applied regression, Fox & Weisberg, Sage
- The elements of statistical learning, Hastie & al., Springer (→ moodle)
- Le machine learning avec Python, Müller & al., O'Reilly
- Forecast verification, Jolliffe & Stephenson, Wiley

Introduction / Apprentissage statistique

1. Apprentissage supervisé :

On cherche à expliquer/prévoir une variable Y (prédicte) au moyen d'autres variables (prédicteurs), 2 situations possibles :

- Y est quantitative $\rightarrow$ modèle de régression
- Y est qualitative $\rightarrow$ modèle de discrimination

2. Apprentissage non supervisé :

Absence de prédicte, on cherche à regrouper les données ayant des caractéristiques proches (recherche de classes) ou à analyser les données dans un sous-espace plus adapté :

$\rightarrow$ méthodes de classification (clustering)


$\rightarrow$ méthodes d'analyse factorielle (ACP)

Apprentissage statistique : complexité $\neq$ qualité

On cherchera à estimer puis exploiter des modèles parcimonieux,
un modèle statistique étant d'autant moins robuste qu'il est complexe :
(robustesse = capacité à généraliser à de nouvelles données)

Illustration du phénomène de sur-apprentissage

Graphé extrait de l'ouvrage The elements of statistical learning, Hastie & al.



→ Un équilibre devra être trouvé entre biais et variance de l'estimateur du prédicand induit par la modélisation.

Objectifs du cours de modélisation linéaire

1. Connaître le cadre théorique du modèle linéaire gaussien
2. Savoir exploiter le modèle linéaire gaussien
3. Maîtriser les procédures de sélection automatique des prédicteurs et de validation du modèle
4. Avoir des notions sur le modèle linéaire généralisé et en particulier la régression logistique

Plan du cours

1. Rappels - Outils mathématiques
2. Modèle linéaire gaussien - Cadre théorique
3. Inférence dans le modèle linéaire gaussien
4. Prédicteurs qualitatifs
5. Validation - Scores
6. Modèle linéaire généralisé - Régression logistique

Prérequis

1. Algèbre linéaire / Calcul matriciel
2. Probabilités / Vecteurs aléatoires gaussiens
3. Estimateurs / Maximisation de la vraisemblance
4. Tests statistiques / Utilisation de la p-valeur d'un test

Plan du cours

1. *Rappels*

2. Modèle linéaire gaussien

3. Inférence

4. Prédicteurs qualitatifs

5. Validation

6. Modèle linéaire généralisé (GLM)

Résultats utiles

• Vecteur aléatoire dans $\mathbb{R}^n$

Y_i ($i = 1, \dots, n$) = variables aléatoires réelles

ξ_i = $i^{\text{ème}}$ vecteur de la base canonique

$$Y = \begin{pmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \vdots \\ Y_n \end{pmatrix} = Y_1 \xi_1 + Y_2 \xi_2 + \dots + Y_n \xi_n \qquad E[Y] = \begin{pmatrix} E[Y_1] \\ E[Y_2] \\ E[Y_3] \\ \vdots \\ E[Y_n] \end{pmatrix}$$

Y vecteur aléatoire de $\mathbb{R}^n$ de vecteur espérance $E[Y]$

Matrice de covariance de Y : $V[Y] = \Gamma_Y = E[(Y - E[Y])^t(Y - E[Y])]$
 = matrice symétrique,
 de terme général $\text{COV}(Y_i, Y_j)$

Résultats utiles

Soit A matrice $m \times n$ non aléatoire, et soit $Z = AY$.

$$E[Z] = A E[Y] \quad \text{et} \quad V[Z] = A V[Y] {}^t A$$

- Loi normale multidimensionnelle dans $\mathbb{R}^n$

Y vecteur gaussien : toute combinaison linéaire de ses composantes suit une loi de Gauss à une dimension.

Si $\Gamma_Y = V[Y]$ est inversible, Y admet pour densité, avec $E[Y] = \mu$:

$$f(Y) = \frac{1}{\sqrt{(2\pi)^n \det(\Gamma_Y)}} \exp\left(-\frac{1}{2} {}^t(Y - \mu) \Gamma_Y^{-1} (Y - \mu)\right)$$

A matrice $m \times n$, $Z = AY$, et $Y \sim N_n(\mu, \Gamma_Y) \Rightarrow Z \sim N_m(A\mu, A \Gamma_Y {}^t A)$

Résultats utiles

- **Cadre sphérique**

La loi normale **sphérique** : $\Gamma_Y = \sigma^2 I_n$

Composantes de Y décorrélées (et indépendantes car cadre gaussien)

Composantes de Y de même variance σ^2

- **métrique euclidienne :**

$\langle X, Y \rangle = \sum_i X_i Y_i$ **produit scalaire canonique**

$\|Y\|^2 = \langle Y, Y \rangle = \sum_i Y_i^2 = {}^t Y Y$

→ **densité normale sphérique :**
$$\frac{1}{(\sigma\sqrt{2\pi})^n} \exp\left(-\frac{1}{2\sigma^2}\|Y - \mu\|^2\right)$$

- **propriété importante :** $Y \sim N_n(\mu, \sigma^2 I_n) \Rightarrow \|Y - \mu\|^2 / \sigma^2 \sim \chi_n^2$

Résultats utiles

- **Projection orthogonale**

Q sous-espace de $\mathbb{R}^n$ de dimension q

Π_Q matrice de projection orthogonale sur Q

$\Pi_Q Y$ projeté orthogonal de Y sur Q

$\Pi_Q Y$ défini par $\Pi_Q Y \in Q$ et $(Y - \Pi_Q Y) \perp$ à tout vecteur de Q

Π_Q matrice symétrique idempotente : $\Pi_Q = {}^t\Pi_Q = \Pi_Q^2$

$\text{tr}(\Pi_Q) = \dim Q = q$

Si T matrice $n \times q$ de rang q avec $Q = \text{Im}(T)$, alors on a : $\Pi_Q = T ({}^t T T)^{-1} {}^t T$

Plan du cours

1. Rappels

2. Modèle linéaire gaussien

3. Inférence

4. Prédicteurs qualitatifs

5. Validation

6. Modèle linéaire généralisé (GLM)

Modèle linéaire gaussien : formulation

$$\mathbf{Y} = \mathbf{T} \boldsymbol{\beta} + \mathbf{e} \quad \text{avec} \quad \mathbf{e} \sim \mathbf{N}_n(\mathbf{0}, \sigma^2 \mathbf{I}_n)$$

= comp. déterministe + comp. aléatoire

Y : Vecteur aléatoire gaussien de $\mathbb{R}^n$, de composantes les n observations de la **variable quantitative expliquée** (= prédicand)

T : Matrice $n \times q$ non aléatoire dont les colonnes contiennent les n observations sur les q variables explicatives (= prédicteurs)

β : Vecteur de composantes les q **paramètres du modèle** (à estimer)

e : Vecteur aléatoire gaussien de $\mathbb{R}^n$ contenant les **résidus du modèle**.
Le vecteur $\mathbf{e}$ suit une loi normale sphérique centrée et de matrice de covariance diagonale $\sigma^2 \mathbf{I}_n$ (avec σ^2 à estimer)

q = dimension du modèle

n = dimension de l'archive d'apprentissage

Formulation

En notant x_{ij} la $i^{\text{ème}}$ coordonnée du vecteur X_j ,
pour $i=1,\dots,n$ on peut écrire :

$$Y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_q x_{iq} + e_i$$

Soit, sous forme matricielle :

$$\begin{pmatrix} Y_1 \\ \cdot \\ \cdot \\ \cdot \\ Y_n \end{pmatrix} = \begin{pmatrix} \cdot & \cdot & & \cdot \\ \cdot & \cdot & & \cdot \\ X_1 & X_2 & \dots & X_q \\ \cdot & \cdot & & \cdot \\ \cdot & \cdot & & \cdot \end{pmatrix} \begin{pmatrix} \beta_1 \\ \cdot \\ \beta_q \end{pmatrix} + \begin{pmatrix} e_1 \\ e_2 \\ \cdot \\ \cdot \\ e_n \end{pmatrix}$$

Avec $T=(X_1|X_2|\dots|X_q)$: $Y = T \beta + e = \sum \beta_j X_j + e$

T = matrice du plan d'expérience = "*design matrix*"

Formulation

Y est donc un vecteur aléatoire suivant une loi normale sphérique, dont le vecteur espérance est modélisé linéairement :

$$\mathbf{E}[\mathbf{Y}] = \mathbf{T}\boldsymbol{\beta} \quad \text{et} \quad \mathbf{V}[\mathbf{Y}] = \mathbf{V}[\mathbf{T}\boldsymbol{\beta} + \mathbf{e}] = \mathbf{V}[\mathbf{e}] = \sigma^2 \mathbf{I}_n$$

$$\rightarrow \mathbf{Y} \sim \mathbf{N}_n(\mathbf{T}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$$

Les **résidus $\mathbf{e}_i$** ($i=1,\dots,n$) sont des variables aléatoires **normales**, **centrées**, **indépendantes**, de **variance constante** (homoscédasticité).

$\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_q$ vecteurs contenant les n observations des q variables explicatives.

$\mathbf{X}_j$ ($j=1,\dots,q$) peut être le vecteur des observations d'une variable numérique (prédicteur quantitatif), un vecteur d'indicateurs (prédicteur qualitatif), un vecteur de coordonnées égales à 1 (estimation du terme constant du modèle)

Formulation

Remarques

1. **Modèle linéaire = linéarité selon β**

Les prédicteurs peuvent être transformés dans le but de créer des prédicteurs plus adaptés aux données (prédicteurs élaborés).

L'introduction de termes d'interaction entre prédicteurs peut être bénéfique.

Exemple : le modèle défini par $Y = \beta_1 \ln(X_1) + \beta_2 \exp(X_2) + \beta_3 X_1 \cdot X_2 + e$, exploitant 3 prédicteurs élaborés, entre dans le cadre du modèle linéaire.

2. Vocabulaire : **régression multiple et modèle linéaire**

Les prédicteurs sont considérés comme non aléatoires lorsque l'on raisonne en terme de modèle linéaire.

En régression, les prédicteurs sont considérés comme étant aléatoires et le conditionnement apparaît alors explicitement, les 2 approches étant équivalentes

$$E[Y] \rightarrow E[Y|X_1, \dots, X_q]$$

$$V[Y] \rightarrow V[Y|X_1, \dots, X_q]$$

Estimation dans le modèle linéaire gaussien

- Estimation de β par la méthode MCO (= Moindres Carrés Ordinaires)

$\hat{\beta}$ = estimateur de β

On cherche à **minimiser** $\sum e_i^2 = \|e\|^2 = \|Y - T\beta\|^2$

→ $\hat{\beta} = \underset{\beta \in \mathbb{R}^q}{\text{ARGMIN}} (\|Y - T\beta\|^2)$

$$\hat{\beta} \text{ tel que : } \left. \frac{\partial \|Y - T\beta\|^2}{\partial \beta} \right|_{\beta=\hat{\beta}} = 0 \quad (\text{et hessienne définie positive})$$

Par dérivation vectorielle, il vient : $-2^t T(Y - T\hat{\beta}) = 0$

Estimation

D'où l'expression de l'estimateur des moindres carrés de β ,
avec T de rang q :

$$\hat{\beta} = \left({}^t T T \right)^{-1} {}^t T Y$$

Propriété : $\hat{\beta}$ est un **estimateur sans biais** de β : $E[\hat{\beta}] = \beta$

Théorème de Gauss-Markov :

$\hat{\beta}$ est de tous les estimateurs linéaires sans biais de β (de la forme AY)
celui de **variance minimale**.


→ BLUE : Best Linear Unbiased Estimator

Estimation

- **Interprétation géométrique**

Soit Q le sous-espace de $\mathbb{R}^n$ engendré par les vecteurs colonnes de T .
Le projecteur Π_Q sur Q s'écrit : $\Pi_Q = T ({}^t T T)^{-1} {}^t T$

On note Y^* le vecteur des valeurs ajustées de Y par le modèle :
 $Y^* = T \hat{\beta} = T ({}^t T T)^{-1} {}^t T Y = \Pi_Q Y$



→ Y^* est donc la projection orthogonale de Y sur Q

$\varepsilon = Y - Y^* = Y - T \hat{\beta}$ = vecteur des résidus estimés du modèle.

Estimation

- **Loi de $\hat{\beta}$**

Y étant un vecteur aléatoire, $\hat{\beta}$ fonction de Y est aussi un vecteur aléatoire.

Dans le cadre du modèle linéaire gaussien, $\hat{\beta}$ transformé linéaire d'un vecteur gaussien est lui-même gaussien et on a :

$$\hat{\beta} \sim N_q \left(\beta, \sigma^2 \left({}^t T T \right)^{-1} \right)$$

Exercice : retrouver les expressions de $E[\hat{\beta}]$ et $V[\hat{\beta}]$.

Estimation

- Le vecteur $\hat{\beta}$ suit une loi normale multidimensionnelle de dimension q , d'espérance β et de matrice de variance-covariance $\sigma^2({}^t\mathbf{T}\mathbf{T})^{-1}$
- Cette matrice de variance-covariance n'est en général pas diagonale : les estimateurs $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_q$ n'étant alors pas indépendants.

Soit $\hat{\beta}_k$ ($k=1, \dots, q$) la $k^{\text{ième}}$ composantes de $\hat{\beta}$:

$\hat{\beta}_k$ suit donc une loi normale :

- d'espérance β_k
- d'écart-type $\sigma_k = \sigma \sqrt{({}^t\mathbf{T}\mathbf{T})_{kk}^{-1}}$

avec $({}^t\mathbf{T}\mathbf{T})_{kk}^{-1}$: $k^{\text{ième}}$ élément diagonal de la matrice $({}^t\mathbf{T}\mathbf{T})^{-1}$

Estimation


• Estimation de σ^2

Soient ε le vecteur des résidus estimés ($\varepsilon = Y - T\hat{\beta}$) et e le vecteur des résidus théorique ($e = Y - T\beta$).

$\varepsilon = Y - Y^* = Y - T\hat{\beta}$ est orthogonal à Q : $\varepsilon \in Q^\perp$

$\Pi_Q = T(T^T T)^{-1} T^T$ est le projecteur sur Q

$\Pi_{Q^\perp} = I_n - \Pi_Q$ est le projecteur sur $Q^\perp$ (I_n matrice identité de $\mathbb{R}^n$).



Exercice : déterminer la loi du vecteur ε

Formulation

On montre que : $E[\|Y - T\hat{\beta}\|^2] = \sigma^2 (n-q)$

On en déduit donc un estimateur de σ^2 :

$$\hat{\sigma}^2 = \frac{\|Y - T\hat{\beta}\|^2}{n - q} = \frac{\|Y - Y^*\|^2}{n - q} = \frac{\|\varepsilon\|^2}{n - q} = \frac{\sum_{i=1}^n (Y_i - Y_i^*)^2}{n - q}$$

On montre que $\hat{\sigma}^2$ est l'estimateur sans biais de variance minimale de σ^2 .

ε = projection orthogonale de e (et de Y) sur $Q^\perp$

$$\frac{\|Y - T\hat{\beta}\|^2}{\sigma^2} \sim \chi_{n-q}^2 \quad (\text{Th. De Cochran})$$

Exercice

1. A partir de l'expression de la densité normale multidimensionnelle,

$$f(Y) = \frac{1}{\sqrt{(2\pi)^n \det(\Gamma)}} \exp\left(-\frac{1}{2} {}^t(Y - \mu) \Gamma^{-1} (Y - \mu)\right)$$

définir la fonction de vraisemblance associée à un n vecteur aléatoire Y dans le cadre du modèle linéaire gaussien.

2. Calculer les estimateurs $\hat{\beta}_{MV}$ et $\hat{\sigma}_{MV}^2$ obtenus par la méthode de maximisation de la vraisemblance.
3. L'estimateur $\hat{\sigma}_{MV}^2$ est-il biaisé ?

Plan du cours

1. Rappels
2. Modèle linéaire gaussien
- 3. *Inférence***
4. Prédicteurs qualitatifs
5. Validation
6. Modèle linéaire généralisé (GLM)

Tests dans le modèle linéaire gaussien

- **Test du caractère significatif de l'une des composantes de β**

$$\hat{\beta}_k \sim N(\beta_k, \sigma_k^2) \text{ avec } \sigma_k^2 = \sigma^2 ({}^t T T)_{kk}^{-1}$$

On a le résultat théorique suivant :

$$\frac{(\hat{\beta}_k - \beta_k)}{\hat{\sigma}_k} = \frac{(\hat{\beta}_k - \beta_k)}{\sqrt{\frac{\|Y - T\hat{\beta}\|^2}{n-q} \cdot ({}^t T T)_{kk}^{-1}}} \sim Student_{n-q}$$

avec : $\hat{\sigma}_k = \sqrt{\hat{\sigma}_k^2} = \sqrt{\hat{\sigma}^2 ({}^t T T)_{kk}^{-1}}$

On peut alors en déduire l'intervalle de confiance de β_k ainsi que le test du caractère significatif de β_k .

Prévision d'une nouvelle valeur du prédicand

Soit $\mathbf{t}_k$ une nouvelle observation des q prédicteurs : $\mathbf{t}_k = (\mathbf{x}_{k1}, \dots, \mathbf{x}_{kq})$

$$Y_k^* = \hat{\beta}_1 \mathbf{x}_{k1} + \hat{\beta}_2 \mathbf{x}_{k2} + \hat{\beta}_3 \mathbf{x}_{k3} + \dots + \hat{\beta}_q \mathbf{x}_{kq} = \mathbf{t}_k \hat{\beta}$$

Y_k^* transformé linéaire de $\hat{\beta} \Rightarrow Y_k^* \sim N(\mathbf{t}_k \beta, \sigma^2 \mathbf{t}_k (\mathbf{t} \mathbf{T} \mathbf{T})^{-1} \mathbf{t}_k)$

Par studentisation, puisque σ^2 doit être estimé, et Y_k aléatoire, on trouve :

$$\frac{Y_k^* - Y_k}{\hat{\sigma} \sqrt{1 + \mathbf{t}_k (\mathbf{t} \mathbf{T} \mathbf{T})^{-1} \mathbf{t}_k}} \sim \text{Student}_{n-q}, \text{ avec } \hat{\sigma} = \sqrt{\hat{\sigma}^2}$$

$\Rightarrow$ intervalle de prévision de Y_k , de confiance $(1 - \alpha)$:

$$Y_k^* - s_{n-q, 1-\alpha/2} \hat{\sigma} \sqrt{1 + \mathbf{t}_k (\mathbf{t} \mathbf{T} \mathbf{T})^{-1} \mathbf{t}_k} < Y_k < Y_k^* + s_{n-q, 1-\alpha/2} \hat{\sigma} \sqrt{1 + \mathbf{t}_k (\mathbf{t} \mathbf{T} \mathbf{T})^{-1} \mathbf{t}_k}$$

avec $s_{n-q, 1-\alpha/2}$ = quantile d'ordre $1-\alpha/2$ de la loi de Student à $n-q$ degrés de liberté

Coefficient de corrélation multiple R

R est le coefficient de corrélation entre les valeurs observées Y et les valeurs ajustées Y* par le modèle statistique.

Son carré R², appelé **coefficient de détermination**, mesure la qualité du modèle et s'interprète en termes de variance expliquée :

$$R^2 = \frac{\text{variance expliquée}}{\text{variance totale de Y}} = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

Formule de décomposition de la variance :

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - Y_i^*)^2 + \frac{1}{n} \sum_{i=1}^n (Y_i^* - \bar{Y})^2$$

Variance totale (SCT) = Variance résiduelle (SCR) + Variance expliquée (SCE)

Test de significativité du R^2 (test de Fisher global)

Soit $H_0 : R^2 = 0$ (hypothèse de non-régression)
 $H' : R^2 > 0$

$$F = \frac{R^2}{1 - R^2} \cdot \frac{n - q}{q - 1} = \frac{\sum_{i=1}^n (Y_i - \bar{Y})^2}{\sum_{i=1}^n (Y_i - Y_i^*)^2} \cdot \frac{n - q}{q - 1}$$

Sous H_0 , F suit une loi de Fischer-Snédecors à $q-1$ et $n-q$ degrés de liberté.

Au niveau α , on rejette H_0 si $F > f_{q-1, n-q, \alpha}$ (ou $p\text{-value} < \alpha$)

Ce test compare le modèle complet au modèle ne comportant que le terme constant et vérifiant $E[Y] = \beta_0$

Sélection de prédicteurs : test de Fisher

Principe de parcimonie :

A qualité d'information égale (performances proches), on privilégiera toujours le modèle le moins complexe (= gage de robustesse).

- Test de Fisher :

R^2 augmente « mécaniquement » avec la dimension du modèle, même si l'information apportée n'est pas pertinente. En effet R^2 ne tient pas compte de la dimension du sous espace de projection Q.

→ On teste donc la significativité de l'accroissement de R^2 :

Modèle complet à $k+p$ prédicteurs, et modèle restreint à k prédicteurs

$$H_0 : R_k^2 = R_{k+p}^2 \quad F = \frac{n - k - p}{p} \cdot \frac{R_{k+p}^2 - R_k^2}{1 - R_{k+p}^2}$$

$$H' : R_k^2 < R_{k+p}^2$$

Sous H_0 , on montre que F suit une loi de Fisher à p et $n-k-p$ degrés de liberté.

On rejettera donc H_0 au niveau α si $F > f_{p,n-k-p,\alpha}$ (ou p-value $< \alpha$)

Remarque : autres critères de sélection courants :

AIC, BIC, C_p de Mallows, R^2 ajusté (cf.TP)

Sélection de prédicteurs

Algorithmes de sélection automatique des prédicteurs :

Procédure optimale :

Comparaison de toutes les combinaisons possibles de prédicteurs, mais il faut alors estimer et confronter 2^q modèles, ...soit près de 10^{30} modèles pour une centaine de prédicteurs potentiels.

- **Sélection descendante** : on retire du modèle complet les variables inutiles une à une, avec une règle d'arrêt (baisse significative du R^2 , AIC minimal...)
- **Sélection ascendante** : on introduit dans le modèle à chaque étape la variable la plus utile, avec une règle d'arrêt (accroissement de R^2 non significatif par exemple) : à privilégier si nb important de prédicteurs.
- **Sélection avec remise en cause** : on introduit dans le modèle à chaque étape une variable supplémentaire, et on teste si toutes les variables sont utiles, avec une règle d'arrêt.

Plan du cours

1. Rappels
2. Modèle linéaire gaussien
3. Inférence
- 4. *Prédicteurs qualitatifs***
5. Validation
6. Modèle linéaire généralisé (GLM)

Prédicteurs qualitatifs : ANOVA

L'analyse de variance (ANOVA en anglais) est une technique qui permet de **quantifier l'effet de variables *qualitatives* sur une variable *quantitative***.

- **Analyse de variance à un facteur**

Soit Y la variable quantitative à expliquer. On considère ici l'effet moyen d'une variable qualitative (appelée facteur) à p modalités.

Le modèle s'écrit : $Y_{ik} = \mu + \alpha_i + e_{ik}$

Avec : $i=1,\dots,p$ $k=1,\dots,n_i$ $\sum_{i=1}^p n_i = n$ $e \sim N(0, \sigma^2 I_n)$

μ est la valeur moyenne de Y , i la $i^{\text{ème}}$ modalité du facteur α , α_i l'effet moyen de la $i^{\text{ème}}$ modalité de α , et Y_{ik} la $k^{\text{ème}}$ observation de Y dans la catégorie i .

Prédicteurs qualitatifs : ANOVA

Modèle linéaire où les variables prédictors sont remplacées par le tableau d'indicatrices des modalités du facteur α . (exemple avec $p=3$)

$$\begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{21} \\ Y_{22} \\ Y_{23} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix} \cdot \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{pmatrix} + \begin{pmatrix} e_{11} \\ e_{12} \\ e_{13} \\ e_{21} \\ e_{22} \\ e_{23} \\ e_{31} \\ e_{32} \end{pmatrix}$$

PROBLEME : T n'étant pas de plein rang, les calculs ne peuvent être menés :

→ Le modèle est alors non identifiable.

Prédicteurs qualitatifs : ANOVA

→ Contrainte d'identification nécessaire :

$$\sum_{i=1}^p \alpha_i = 0 \quad \Leftrightarrow \quad \alpha_p = -\sum_{i=1}^{p-1} \alpha_i$$

(Remarque : d'autres contraintes peuvent être utilisées, le choix de la contrainte n'impacte pas le modèle lui-même mais l'interprétation des paramètres finalement estimés → (cf. TD & TP))

Sous cette dernière contrainte, le modèle s'écrit :

$$\begin{pmatrix} Y_{11} \\ Y_{12} \\ Y_{13} \\ Y_{21} \\ Y_{22} \\ Y_{23} \\ Y_{31} \\ Y_{32} \end{pmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & -1 & -1 \\ 1 & -1 & -1 \end{bmatrix} \cdot \begin{pmatrix} \mu \\ \alpha_1 \\ \alpha_2 \end{pmatrix} + \begin{pmatrix} e_{11} \\ e_{12} \\ e_{13} \\ e_{21} \\ e_{22} \\ e_{23} \\ e_{31} \\ e_{32} \end{pmatrix}$$

Les calculs peuvent alors être menés.

Prédicteurs qualitatifs : ANCOVA

- **Analyse de covariance (ANCOVA)**

Analyse de covariance = mélange de prédicteurs qualitatifs et quantitatifs

- Pas de difficultés particulières
- Une contrainte sera alors imposée pour chaque prédicteur qualitatif
- Par exemple, si la variable Y dépend des variables X_1 , X_2 et des facteurs α et v , on peut écrire :

$$Y_{ijk} = \mu + \beta_1 X_{1ijk} + \beta_2 X_{2ijk} + \alpha_i + v_j + e_{ijk}$$

Plan du cours

1. Rappels
2. Modèle linéaire gaussien
3. Inférence
4. Prédicteurs qualitatifs
- 5. *Validation***
6. Modèle linéaire généralisé (GLM)


Diagnostics et validation

Généralités :

- L'apprentissage du modèle se fera sur un sous-échantillon dédié, une partie des données ayant été préalablement isolée de l'archive afin d'évaluer les performances du modèle en conditions opérationnelles (**phase de test**).
- Un modèle trop complexe manquera de **robustesse** (capacité à généraliser à de nouvelles données), on parle alors de **sur-apprentissage** (cf. TP).

Illustration du phénomène de sur-apprentissage

Graphique extrait de l'ouvrage The elements of statistical learning, Hastie & al.



Courbe bleu :
le score (RMSE par ex.) est estimé sur les données d'apprentissage.

Courbe rouge :
le score est estimé sur de **nouvelles données**, indépendantes des données d'apprentissage, simulant ainsi le comportement du modèle en conditions opérationnelles.

Diagnostics et validation

Equilibre Biais / Variance :

- On cherche à construire un modèle **parcimonieux**.
- Plus le modèle est complexe (flexible) et meilleur sera l'ajustement aux données d'apprentissage (*forte variance & faible biais*).
Mais un modèle trop complexe s'avèrera défaillant pour prévoir de nouvelles données, car trop lié aux données d'apprentissage :
→ incapacité à généraliser = modèle **sur-apprenti**.
- Un modèle trop simple induit une mauvaise qualité d'ajustement
→ modèle **sous-apprenti** (*faible variance & fort biais*).
→ **Objectif du statisticien** : Optimiser le dosage entre biais et variance en contrôlant l'ajustement aux données et la complexité du modèle.

(Chaque méthode statistique comportera un ou plusieurs paramètres de complexité à régler, la dimension du modèle linéaire gaussien par ex.)

Diagnostics et validation : sur-apprentissage

Soit le couple d'observations (x_0, y_0) et le modèle théorique $y_0 = f(x_0) + e_0$, avec $e_0 \sim N(0, \sigma^2)$

$$\begin{aligned} E[(\hat{f}(x_0) - y_0)^2] &= E[(\hat{f}(x_0) - f(x_0))^2] + E[e_0^2] - 2E[(\hat{f}(x_0) - f(x_0))e_0] \\ &= V[\hat{f}(x_0)] + \left(BLAIS[\hat{f}(x_0)]\right)^2 + \sigma^2 - 2E[(\hat{f}(x_0) - f(x_0))(y_0 - f(x_0))] \end{aligned}$$

Deux situations sont alors à considérer selon le statut des observations utilisées :

1^{er} cas : Les observations (x_0, y_0) proviennent de l'archive de test :

y_0 et son estimation sont indépendantes, le 4^e terme est alors nul et on a :

$$E[(\hat{f}(x_0) - y_0)^2] = V[\hat{f}(x_0)] + \left(BLAIS[\hat{f}(x_0)]\right)^2 + \sigma^2 = Err$$

Avec la complexité (flexibilité) du modèle, la variance croît alors que le biais décroît.

2^e cas : Les observations (x_0, y_0) proviennent de l'archive de d'apprentissage :

y_0 et son estimation sont liées, le 4^e terme est alors non nul et on montre qu'on a :

$$E[(\hat{f}(x_0) - y_0)^2] = V[\hat{f}(x_0)] + \left(BLAIS[\hat{f}(x_0)]\right)^2 + \sigma^2 - 2\sigma^2 E\left[\frac{\partial \hat{f}(x_0)}{\partial y_0}\right] = Err - S$$

Le terme S, lié à la complexité du modèle, fausse l'estimation de l'erreur réelle du modèle.

Positif et augmentant avec la complexité, ce terme S constitue une mesure du sur-apprentissage.

Diagnostics et validation : erreur de prévision

Constat :

L'estimation de l'erreur sur apprentissage est trop optimiste, le modèle y étant d'autant plus fiable qu'il est complexe. Cette estimation est faussée par le fait que les mesures du prédictand ne sont alors pas indépendantes de leur estimateur.

Stratégies d'estimation de l'erreur de prévision :

- **Estimation avec pénalisation** : pénalisation de l'erreur d'ajustement sur apprentissage par la complexité du modèle (critères **AIC**, **BIC**...).
(utilisée par les algorithmes de sélection automatique des prédicteurs, cf. TP)
- **Validation croisée** : itérer l'estimation de l'erreur sur plusieurs échantillons de test en scindant l'échantillon d'origine, puis moyenner ces estimations.
(stratégie améliorant la précision de l'estimation)
L'étude de la variabilité de ces estimations permet aussi de juger de la significativité des écarts de performance constatés entre 2 modèles.

Diagnostics et validation : mode opératoire

- Extraction, exploration, pré-traitement des données.
- Partition de l'échantillon en fichiers d'**apprentissage / validation / test**.
- Estimation du modèle sur l'archive d'apprentissage pour une valeur des paramètres de complexité (hyperparamètres) puis ajustement afin d'éviter le sur-apprentissage, par analyse du comportement de l'erreur sur l'archive de validation.
(analyse de la **robustesse**)
- Différentes méthodes statistiques seront confrontées sur l'archive de test, après validation de chacune, pour en sélectionner une en fonction de ses capacités de prévision, sa robustesse mais aussi éventuellement de l'**interprétabilité du modèle**.

Diagnostics et validation

- **Multicolinéarité et calcul explicite de $({}^t\text{TT})^{-1}$**

Si ${}^t\text{TT}$ est mal conditionnée, son déterminant est proche de zéro.



variance élevée des estimateurs

→ estimateurs instables, conclusions peu fiables

Diagnostic : facteur d'inflation de la variance (VIF) : $V_j = \frac{1}{1 - R_j^2}$

R_j^2 coefficient de détermination multiple de la régression de la $j^{\text{ème}}$ variable avec toutes les autres. De fortes valeurs du VIF permettent d'identifier et de retirer les variables posant problème (pb si $VIF > 10$), on peut également combiner ces variables pour créer un prédicteur élaboré.

Régression en composantes principales :

Permet de résoudre les problèmes de multicolinéarité lorsque l'on tient à conserver toutes les variables.

(Attention, les composantes les plus informatives pour l'explication de Y ne sont en général pas rangées dans le même ordre que les valeurs propres)

Diagnostics et validation

- Etude des résidus

**L'étude des résidus après estimation est *FONDAMENTALE*.
Elle permet de vérifier les hypothèses de base du modèle linéaire, de repérer les données pathologiques, et de mettre en évidence les inadéquations au modèle.**

Avant estimation : analyses uni et bivariées, afin d'identifier des problèmes sur les distributions de chacune des variables (dissymétrie, valeurs atypiques) ou sur les liaisons des variables prises deux par deux (non linéarité de la liaison)
→ création d'un prédicteur élaboré plus adapté aux données).

Après estimation : détection des violations d'hypothèses (linéarité, indépendance, homoscedasticité) ou de points influents dans le contexte multidimensionnel (cf. TP).

Diagnostics et validation

1. Normalité non respectée

- estimations de β et σ^2 restent sans biais
- $\hat{\beta}$ n'est plus exactement normal, ni optimal
- les tests de Student et Fisher sont biaisés

Les théorèmes centraux-limites généralisés relativisent l'influence de la non-normalité des données :

Echantillon suffisamment grand + loi des données pas trop dissymétrique
→ propriétés de normalité de $\hat{\beta}$ et exactitude des tests à peu près conservées.

Vérification :

diagrammes quantiles/quantiles, tests de Kolmogorov-Smirnov, Shapiro...

Diagnostics et validation

2. Non-indépendance

- Les estimateurs restent non biaisés mais ne sont plus optimaux
- Concerne les données issues de séries chronologiques
- Décorrélation totale souvent difficile à obtenir

Tant que la corrélation temporelle reste faible, ce n'est pas très gênant.


En cas de problèmes importants :

modèle autorégressif ou estimation par Moindres Carrés Généralisés.

Vérification : corrélogramme des résidus, test de Durbin-Watson

Diagnostics et validation


3. Inadéquation



Le graphe des résidus en fonction de Y^* permet de vérifier les propriétés d'adéquation et d'homoscédasticité du modèle.

La relation entre Y et Y^* n'est ici pas linéaire. L'analyse du problème doit être améliorée, en proposant d'autres prédicteurs ou en les transformant, ce qui peut être fait sans précautions particulières.

4. Hétéroscédasticité



La structure de la variance est la **pathologie la plus problématique**. Seules les propriétés de non biais et de convergence de $\hat{\beta}$ sont conservées.

Nécessite un changement de variable, ou l'emploi de techniques de **modélisation linéaire généralisée**.

(Vérification : graphique ou tests de Bartlett, Levene)

Diagnostics et validation

5. Observations influentes

Certaines observations peuvent avoir une plus grande influence que d'autres, par **effet levier**.

On utilise généralement la **distance de Cook** pour détecter de telles observations (lorsque $D_i > 1$, la i ème observation est considérée comme pathologique). Une distance entre $\hat{\beta}$ et $\hat{\beta}_{-i}$ est calculée, $\hat{\beta}_{-i}$ étant le vecteur estimé en retirant l'observation i de l'archive d'apprentissage.

Ces observations (points leviers ou valeurs aberrantes) influencent grandement les estimations et doivent donc être retirées.

Cette distance est disponible dans la plupart des logiciels statistiques.

Plan du cours

1. Rappels
2. Modèle linéaire gaussien
3. Inférence
4. Prédicteurs qualitatifs
5. Validation
- 6. *Modèle linéaire généralisé (GLM)***

Modèle linéaire généralisé et fonction de lien

- **Modèle linéaire gaussien :**

L'espérance du prédicteur Y est modélisée linéairement et

conditionnellement aux p prédicteurs :
$$E[Y / X_1, \dots, X_p] = \beta_0 + \sum_{j=1}^p \beta_j X_j$$

- **Modèle linéaire généralisé :** (généralisation à des prédicteurs non gaussiens)

Une fonction de l'espérance du prédicteur Y est modélisée linéairement

et conditionnellement aux p prédicteurs :
$$g(E[Y / X_1, \dots, X_p]) = \beta_0 + \sum_{j=1}^p \beta_j X_j$$

La fonction g , nommée fonction de lien canonique, dépend de la loi suivie par le prédicteur. La théorie du modèle linéaire généralisé montre qu'il existe une fonction de lien pour chaque loi de la famille exponentielle.

Remarque : le modèle linéaire gaussien est donc un cas particulier de modèle linéaire généralisé pour lequel la fonction de lien est la fonction identité.

Famille exponentielle

- La famille exponentielle regroupe de nombreuses loi courantes : Normale, Exponentielle, Gamma, Bêta, Poisson, Bernoulli, Binomiale...
- La loi de Y appartient à la famille exponentielle si sa densité peut s'exprimer sous la forme :

$$f(Y) = \exp \left[\frac{Y\theta - b(\theta)}{a(\phi)} + c(Y, \phi) \right]$$

avec a , b , c trois fonctions arbitraires,

θ paramètre naturel (ou canonique) de la loi, fonction de $E[Y]$:

$\theta = g(E[Y])$ avec g = fonction de lien canonique,

ϕ paramètre d'échelle (absent si la loi ne comporte qu'un paramètre).

Modèle généralisé particulier : la régression logistique

Dans le cas de la régression logistique, le predictand est une variable binaire Y qui suit une loi de Bernoulli de paramètre : $P(Y=1)=E[Y]$

La fonction de lien canonique associée à la loi de Bernoulli est la fonction logit : $g(x) = \ln(x/(1-x))$ ($\rightarrow$ résultat à montrer en exercice)

Un modèle de régression logistique aura donc pour expression :

$$g(E[Y / X_1, \dots, X_q]) = \ln \left(\frac{P(Y = 1 / X_1, \dots, X_q)}{1 - P(Y = 1 / X_1, \dots, X_q)} \right) = \beta_0 + \sum_{j=1}^q \beta_j X_j$$

L'estimation des paramètres se fera par maximisation de la vraisemblance, on obtiendra ensuite une estimation de l'espérance conditionnelle ainsi (fonction logistique = fct réciproque de la fct logit) :

$$\hat{P}(Y = 1 / X_1, \dots, X_p) = g^{-1}(\hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j X_j)$$

$$= \frac{1}{1 + \exp \left[-(\hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j X_j) \right]}$$

Intérêt de la régression logistique

Un modèle de régression logistique va permettre de modéliser l'occurrence d'un phénomène (orage, brouillard...) mais également le dépassement d'un seuil d'un prédictand quantitatif.

Un tel modèle permet donc la discrimination des deux modalités d'un prédictand binaire : occurrence (codée 1) et non occurrence (codée 0).

Le modèle calcule des estimations de probabilités d'occurrence du phénomène étudié, il va donc falloir post-traiter ces probabilités prévues pour définir la prévision binaire (occurrence ou non occurrence prévue).

→ Un seuil de probabilité va donc devoir être exploité pour passer d'une prévision probabiliste à une prévision déterministe (cf. TP et courbe ROC)