

Initiation au logiciel R

commandes de base

HPC – BIG DATA

Avril 2026

- Ressource principale

<http://www.r-project.org/>

- Sites Miroirs du **CRAN** (Comprehensive R Archive Network)
Exemple : CNRS IBCP Lyon

<http://mirror.ibcp.fr/pub/CRAN/>

Bibliographie conseillée :

- Manuels officiels du projet (dispo sur site du CRAN → Manuals)
- **Le logiciel R**, P. Lafaye de Micheaux & al., Springer (→ Biblio'Tech)
- de nombreuses ressources sont disponibles ici :

<https://cran.r-project.org/other-docs.html>

Caractéristiques

Créé en 1993 par R.Ihaka et R.Gentleman, R est à la fois un langage informatique orienté objet et un environnement de travail, codé en C et FORTRAN.

Dernière version depuis mars 2026 : **4.5.3**

▪ Avantages

- Gratuit
- Multi plates-formes MAC, UNIX/LINUX, WINDOWS
- Dédié aux statistiques, grandes possibilités graphiques
- Interprété et non compilé : flexibilité
- Documentation intégrée riche
- Open Source, GNU General Public License
- Enrichi en permanence (près de 23600 packages disponibles à ce jour → CRAN/Packages)
- Possibilité d'exécuter du code C ou FORTRAN depuis R

▪ Inconvénients

- Bugs toujours possibles (mais rapidement corrigés après signalement)
- Prise en main un peu plus difficile que certains logiciels du marché
- Non compilé : pas forcément optimisé (mémoire)
- Attention à l'utilisation de méthodes statistiques non maîtrisées

- Lancer R :
 - Taper la lettre **R**
- Quitter R :
 - taper **q()** , répondre 'y' pour sauvegarder la session

Objets R sauvegardés dans un fichier **.RData**, dans le répertoire courant
Historique de commandes sauvegardé dans un fichier **.Rhistory**
Forcer la sauvegarde par la commande : **save.image()**

De manière générale, R étant orienté objet, même sans arguments les fonctions sont appelées avec des parenthèses.

Installation de “packages” (**linux**)

- Package = bibliothèque de programmes sur un thème donné
- Pour installer le package “nom” :
`install.packages(“nom”,dependencies=TRUE)`
puis choisir un site miroir
- Pour charger le package :
`library(nom)`

Lister les packages

- **library()** : retourne la liste des packages installés
- **search()** : retourne la liste des packages chargés
- **library(LIB)** : charge le package nommé LIB
- **library(help=LIB)** : retourne la liste des fonctions du package LIB

Sessions et programmes

- R peut être utilisé dans une session interactive.
Les variables sont en mémoire dans la session, et peuvent être appelées à tout moment.
- Prenez l'habitude d'écrire vos commandes R dans un fichier script 'nomfic.R' avant de les copier dans la session R.
- On peut également exécuter script R dans une session :
source("prog.R")
 - # lignes de commentaires
 - ; permet d'enchaîner deux commandes sur la même ligne.

- Documentation complète sur le site du CRAN
- Utiliser le “search” du site
- Dans R : ?commande (= alias de help(“commande”))
exemple: **?sd**
Sous LINUX, tapez q pour sortir de l'aide

sd : le fait de taper une commande donne le source
(avantage de l'open source)

- **En-tête du fichier** (nom fonction, nom package, origine du fichier d'aide)
- **Titre** explicite pour la fonction
- **Description** : brève description de ce que fait la fonction
- **Usage** : façon d'utiliser la fonction (param obligatoires et optionnels)
- **Arguments** : description des paramètres d'entrée
- **Details** : remarques particulières
- **Value** : explications sur ce que renvoie la fonction
- **References** : références d'articles ou d'ouvrages
- **See also** : noms de fonctions en rapport avec la fonction courante
- **Examples** : exemples d'utilisation

Nature (ou type ou mode) des données

Type numérique (**numeric**)

- entier (**integer**)
- réel (**real** ou **double**)

Type complexe (**complex**)

Type booléen (**logical**)

Type chaîne de caractères (**character**)

Type variable qualitative (**factor**)

Donnée manquante ou non définie (**NA** : Non Available)

Commandes de bases

Variable dans R :

Commande dans R	Signification
a=5	Affecte la valeur 5 à la variable a
A=7	Affecte la valeur 7 à la variable A
a	Affiche la valeur de la variable a (interactif)
print(a)	affiche la valeur de la variable a (script)

ls()	Liste toutes les variables, tous les objets
rm(nom_objet) / rm(list=ls())	Détruit nom_objet / détruit tous les objets

→ Attention : R est sensible à la casse (Majuscule/Minuscule)

Commandes de bases

Type de variables dans R :

Type	dans R	Signification
numérique	a=5	Affecte le nombre 5 à la variable a
caractère	b= "5"	Affecte le caractère 5 à la variable b
logique	TRUE ou FALSE	Valeur logique VRAI ou FAUX

Conversion :

Notation dans R	Signification
as.numeric(x)	Conversion en numérique
as.integer(x)	Conversion en entier
as.character(x)	Conversion en chaîne de caractères
as.logical(x)	Conversion en variable logique

Commandes de bases

Vérification type de la variable :

Notation dans R	Signification
is.numeric(x)	Renvoie la valeur TRUE si la variable est du type numérique, FALSE sinon
is.integer(x)	Idem pour une variable de type entier
is.character(x)	Idem pour une variable de type caractère
is.logical(x)	Idem pour une variable de type logique

class(x)	Permet de connaître le type d'un objet
----------	--

Commandes de bases

Manipulation de chaîne de caractères :

Notation dans R	Signification
<code>paste(a,b,sep= "")</code>	Concaténation de a et de b sans espace
<code>nchar(a)</code>	Renvoie le nombre de caractères de a
<code>substr(a,1,3)</code>	Extrait de a du caractère 1 au caractère 3
<code>substr(a,1,3)= "12345"</code>	Remplace dans a les caractères 1 à 3 par 123

Fonctions mathématiques usuelles

Notation dans R	Signification
$a + b$	Addition
$a - b$	Soustraction
$a * b$	Multiplication
a / b	Division réelle
$a \%/% b$	Division entière
$a \% b$	Reste de la division
x^a ou $x^{**}a$	Puissance
sqrt (x)	Racine

Fonctions mathématiques usuelles

Notation dans R	Signification
abs(x)	Valeur absolue
round(x,k)	Arrondi de x, k chiffres
log(x)	Logarithme népérien
log10(x)	Logarithme décimal
exp(x)	Exponentielle
sin(x), cos(x), tan(x)	Fonctions trigonométriques
asin(x), acos(x), atan(x)	Inverses trigo
pi	3.14159265.....

Opérateurs logiques

Notation dans R	Signification
==	égalité (logique)
!=	inégalité
<	plus petit
>	plus grand
<=	plus petit ou égal
>=	plus grand ou égal
is.na()	Manquant ?
&	ET logique
 	OU logique
!	NON logique

Structures des données

Structure		Description
Vecteur	vector	suite d'éléments de même nature = objet de base de R
Matrice	matrix	tableau 2D ; éléments de <u>même nature</u>
Tableau	array	tableau de dimension > 2 ; éléments de <u>même nature</u>
Tableau Individus x Variables	data.frame	tableau 2D lignes=individus colonnes=variables (numériques ou facteurs), de nature <u>différente ou non</u> mais de <u>même longueur</u>
Liste	list	suite de structures R de nature différente et quelconque
Facteur Variable ordinale	factor ordered	vecteur de chaînes de caractères associé à des modalités

Vecteurs (structure 'vector')

■ Génération

— Vecteur de chaînes de caractères

- `X=character(20)` génère un vecteur contenant 20 chaînes vides

— Vecteur numérique

- `X=numeric(20)` génère un vecteur contenant 20 zéros
- `X=seq(-4,4,0.1)` génère un vecteur contenant les valeurs
-4.0 -3.9 -3.8 -3.73.7 3.8 3.9 4.0
- `X=1:10` idem `seq(1,10,1)`
- `X=rep(1:5,2)` réplique les valeurs de 1 à 5 deux fois

— Vecteur logique

- `L=logical(20)` génère un vecteur contenant 20 booléens F

— Fonction concaténation : **c()**

- `X=c(0,-1,pi,17.89,20.51960)` génère un vecteur contenant les 5 nombres

Vecteurs

Indexation

Notation dans R	Signification
<code>X[1]</code>	premier élément de X
<code>X[1:5]</code>	5 premiers éléments de X
<code>X[c(1,3,5)]</code>	Éléments n°1, n°3 et n°5 de X
<code>z=c(1,3,5) ; X[z]</code>	
<code>X[X>=5]</code>	Éléments de X qui sont ≥ 5
<code>L=X>=5 ; X[L]</code>	
<code>i=which(X>=5) ; X[i]</code>	

Opérations mathématiques

→ opérations terme à terme, avec éventuellement recyclage (et message d'avertissement)

Vecteurs

Fonctions sur les vecteurs :

Notation dans R	Signification
<code>length(X)</code>	Nombre d'éléments de X
<code>min(X), max(X)</code>	Minimum et maximum des éléments de X
<code>sort(X)</code>	Tri

Structures de données : Matrice (structure 'matrix')

■ Génération

- `matrix(0,nrow=3,ncol=4)`

$$\begin{pmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{pmatrix}$$

- `matrix(1:12,nrow=3,ncol=4)`

$$\begin{pmatrix} 1 & 4 & 7 & 10 \\ 2 & 5 & 8 & 11 \\ 3 & 6 & 9 & 12 \end{pmatrix}$$

- `matrix(1:12,nrow=3,ncol=4,byrow=TRUE)`

$$\begin{pmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \end{pmatrix}$$

Matrices

Indexation

Notation dans R	Signification
$m[i,j]$	élément de m à la i -ème ligne et j -ème colonne
$m[i,]$	i -ème ligne de m
$m[, j]$	j -ème colonne de m
Sélection de lignes et/ou colonnes : idem vecteurs	

Opérations sur les matrices

Notation dans R	Signification
$m1 \%*\% m2$	Multiplication matricielle. <i>Attention aux dimensions</i>
$t(m)$, $\det(m)$	Transposée de m , déterminant de m
$solve(m)$	Inversion matricielle (matrice carrée inversible)

Matrices

Fonctions

Notation dans R	Signification
<code>dim(m)</code>	Dimension de la matrice (nrow,ncol)
<code>nrow(m)</code>	Nombre de lignes de m
<code>ncol(m)</code>	Nombre de colonnes de m
<code>rbind(m,y)</code>	Ajoute une ligne à m (matrice, vecteur, frame) avec les données contenues dans y
<code>cbind(m,z)</code>	Ajoute une colonne à m (matrice, vecteur, frame) avec les données contenues dans z
<code>m[, -2]</code>	Enlève la deuxième colonne à m
<code>m[c(-2,-4),]</code>	Enlève les deuxième et quatrième lignes à m

<code>apply(m,i,fonction)</code>	Applique la fonction aux lignes (i=1) ou aux colonnes (i=2) de la matrice m
----------------------------------	---

Exemples :

```
> g=seq(0,1,length=20)
```

```
> C=matrix(g,nrow=4)
```

Que fait la commande `C[C[,1]>0.1, ]` ?

Utiliser la fonction `apply` pour générer un vecteur contenant les moyenne de chaque colonne.

Structures de données : Tableau (array)

Généralisation de la structure matrix à plus de 2 dimensions

La fonction `apply()` reste utilisable :

> `H=array(1:12,c(2,3,2))`

> `H[,1]` ; `H[1,1]` ; `H[1,,1]`

> `apply(H,1,sum)`

> `apply(H,2,sum)`

> `apply(H,3,sum)`

	1	2	3
1	1	3	5
2	2	4	6

Summary values on the right face: 11 (sum of row 1), 12 (sum of row 2).

Structures de données : Data.frame

Structure spéciale pour les jeux de données de type Ind x Var

La data.frame est une liste de vecteurs de même longueur mais qui peuvent être de natures différentes.

```
> taille = runif(12,150,180) ; masse=runif(12,50,90) ; sexe=rep(c("M","F","F","M"),3)
```

```
> H = data.frame(taille,masse,sexe)
```

```
> H ; summary(H)
```

```
> H$masse ; H$sexe[3]
```

```
> is.data.frame(H) ; class(H)
```

```
> D = subset(H,H$sexe=="F") ; D ; class(D)
```

Bloc de données (data.frame)

Indexation

Notation dans R	Signification
<code>data\$an</code>	Renvoie la variable an de la frame data
<code>data\$an[i]</code>	i-ème valeur de la variable an de la frame data
<code>data[data\$bis==TRUE,]</code>	Sélectionne le sous-ensemble de data correspondant aux années bissextiles
<code>subset(data,bis==TRUE)</code>	

Bloc de données (data.frame)

Fonctions

Notation dans R	Signification
names(data)	Renvoie le nom des variables dans le bloc
et aussi : dim(), nrow(), ncol(), rbind(), cbind(),	
attach(data)	Permet l'appel direct des variables : an au lieu de data\$an
detach(data)	Opération inverse de attach

Attention : pas de lien entre variables attachées et le bloc de départ

apply(data,i,fonction)	Applique la fonction aux lignes (i=1) ou aux colonnes (i=2) de la data.frame data
------------------------	---

Structures de données : Listes (list)

Structure la plus générale (de type « fourre-tout »)

La liste permet de regrouper dans une même structure des données de types différents (vecteurs, matrices, tableaux et même listes) :

```
> A <- list(TRUE,-1:3,matrix(1:4,nrow=2),c(1+2i,3), "chaîne de caractères")
```

```
> B <- list(une.matrice=matrix(1:4,nrow=2),des.complexes=c(1+i,2))
```

Accès aux composants d'une liste soit par le nom soit par le numéro entre double-crochets :

```
> x = list(texte="nuage",1:8) ; x
```

```
> x[[1]] ; x[[2]]+10 ; x$texte
```

Fonction read.table()

La fonction read.table() retourne une data.frame

```
> fic = read.table(file="ozone.txt" , header=TRUE)  
> fic = read.table(file.choose() , header=T)
```

Fonction write.table()

```
> A = seq(1,10,50)  
> write.table(A,"A.txt")
```

Fonction sink()

sink() redirige le résultat des commandes vers un fichier (pas d'affichage écran)

```
> sink("A2.txt") ; A ; summary(A) ; sink() (--> fermeture du fichier)
```

Mode interactif :

```
a = readline("donner la valeur de a : ")
```

Les graphiques : production dans un fichier

Ouverture

Notation dans R	Signification
<code>x11()</code>	fenêtre à l'écran
<code>postscript(file="fig.eps")</code>	fichier postscript
<code>pdf(file="fig.pdf")</code>	fichier pdf

Fermeture

Notation dans R	Signification
<code>graphics.off()</code> ou <code>dev.off()</code>	Ferme toutes les fenêtres graphiques ou finalise le fichier

Les graphiques

Procédure standard : plot

plot(x,y,type="l",main= "titre",)	
Paramètres	Quelques valeurs
type	"l" (ligne), "p" (point), "h" (ligne verticale), ...
main	Titre du graphique
sub	Sous-titre
xlab	Titre de l'axe des abscisses
ylab	Titre de l'axe des ordonnées
xlim=c(a,b),ylim=c(d,e)	Donne l'échelle des axes. Attention par défaut R rajoute 4% aux axes
xaxs= "i" , yaxs= "i"	Permet d'avoir des dimensions exactes
col	Couleur. Pour avoir la liste : colors()

Les graphiques

Contrôle des lignes et des symboles

Paramètres	Quelques valeurs
lwd	largeur de la ligne
lty	type de ligne (pointillé, tiret,)
pch	type de pointage "+", ".",
?par : liste des paramètres graphiques et leur usage	

Les graphiques

Fonctions graphiques secondaires

Notation dans R	Signification : sur un graphique existant
<code>lines(x,y)</code>	rajoute des lignes
<code>points(x,y)</code>	pointage
<code>text(x,y,"texte")</code>	rajoute du texte au point x,y
<code>abline(b,a)</code>	rajoute une droite $y=ax+b$
<code>abline(h=y)</code>	ligne horizontale (hauteur=y)
<code>abline(v=x)</code>	ligne verticale (position=x)

Les graphiques

Fonctions statistiques descriptives graphiques

Notation dans R	Signification
hist(x)	Histogramme
boxplot(x)	Boîtes à moustaches

Autres possibilités

Graphes multiples

Contour 2D

Graphes 3D

Cartes

La programmation

■ Test

```
if (toto==2)
    {tata=1}
```

```
if (toto==2)
    {tata=1} else
    {tata=0}
```

■ Boucle

```
for (i in 1:10)
    { tata[i]=exp(toto[i])}
```

```
i=1
while (i < 10)
    {tata[i]=exp(toto[i])
    i=i+1}
```

Attention, l'opérateur ":" est prioritaire,
comparer 1:10-1 et 1:(10-1)

Fonctions

- Définition

```
ect=function(x)
{resultat=sqrt(var(x))
return(resultat)}
```

- Utilisation

```
s=ect(x)
```

- Emploi de listes

```
moyect=function(x)
{s=ect(x)
m=mean(x)
resultat=list(moyenne=m,ect=s)
return(resultat)}
```

Un peu de PROBA / STAT

Fonctions statistiques descriptives

Notation dans R	Signification
sum(x)	somme des éléments de x
mean(x)	moyenne des éléments de x
var(x)	variance des éléments de x
sd(x)	écart-type des éléments de x
median(x)	médiane des éléments de x
quantile(x,p)	quantile d'ordre p des éléments de x

summary(x)	Certains paramètres descriptifs de x
------------	--------------------------------------

Un peu de PROBA / STAT

Distribution de probabilité

Convention : d=densité, p=répartition, q=quantile, r=random

Loi normale d'espérance m et d'écart-type s : norm(...,m,s)	
Notation dans R	Signification
d norm(x,m,s)	densité de x
p norm(x,m,s)	fonction de répartition de x
q norm(p,m,s)	quantile d'ordre p
r norm(n,m,s)	génération de n nombres aléatoires distribués selon $N(m,s)$

Lois de probabilité

Convention : d=densité, p=répartition, q=quantile, r=random

Notation dans R

`unif(,min,max)`

`t(,df)`

`chisq(,df)`

`f(,d1,d2)`

`pois(,lambda)`

`exp(,lambda)`

Etc

Signification

loi uniforme sur [min,max]

loi de student à df ddl

loi du χ^2 à df ddl

loi de Fisher à d1 et d2 ddl

loi de Poisson d'intensité lambda

loi exponentielle de param lambda

Fonctions statistiques descriptives

Notation dans R

Signification

<code>sum(x)</code>	somme des éléments de x
<code>mean(x)</code>	moyenne des éléments de x
<code>var(x)</code>	variance des éléments de x
<code>sd(x)</code>	écart-type des éléments de x
<code>median(x)</code>	médiane des éléments de x
<code>quantile(x,p)</code>	quantile d'ordre p des éléments de x
<code>summary(x)</code>	Certains paramètres descriptifs de x

Tests statistiques classiques

Notation dans R	Signification
t.test	comparaison des moyennes (Student ou Welch)
var.test	comparaison des variances (Fisher)
cor.test	test de corrélation.
ks.test	test de Kolmogorov-Smirnov
shapiro.test	test de normalité de Shapiro-Wilk
chisq.test	test du Khi2

Régression Linéaire

Notation dans R	Signification
$\text{lm}(y \sim x)$	Régression linéaire simple de y par x (avec ordonnée à l'origine)
$\sim$	« Expliqué par »
$\text{lm}(y \sim -1 + x)$	-1 retire le terme constant qui par défaut serait estimé

Régression Linéaire sous R : syntaxe

Notation dans R	Signification
<code>lm.out = lm(Y~X,data)</code>	Estime le modèle de régression de Y par X et stocke les résultats dans l'objet <code>lm.out</code> ; Y et X étant des colonnes du <code>data.frame</code> nommé <code>data</code> .
<code>lm.out = lm(Y~X+Z,data)</code>	Régression multiple de Y par X et Z
<code>summary(lm.out)</code>	Résumé des résultats (cf. diapo suivante) : modèle, coefficients, tests, etc..
<code>coefficients(lm.out)</code> ou <code>lm.out\$coefficients</code>	Vecteur contenant les estimations des coefficients du modèle
<code>fitted(lm.out)</code> ou <code>lm.out\$fitted.values</code>	Vecteur contenant les valeurs ajustées par le modèle (= prévisions sur apprentissage)
<code>residuals(lm.out)</code> ou <code>lm.out\$residuals</code>	Vecteur contenant les erreurs estimées du modèle
<code>predict(lm.out,newdata)</code>	Valeurs de Y prévues pour un nouveau bloc de données <code>newdata</code> organisé comme data

Interprétation de la commande `summary(lm.out)`

`lm(formula = Y ~ X + Z, data = data)`

Residuals:

Min	1Q	Median	3Q	Max
-107.147	-18.980	-1.225	18.011	153.780

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	-19.92126	4.36472	-4.564	5.61e-06	***
X	0.41998	0.02475	16.966	< 2e-16	***
Z	3.42883	0.18893	18.149	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Estimation de chaque coefficient

Ecart-type associé à chaque estimation

Statistique de test et p-value du test de Student évaluant la significativité de chaque coefficient du modèle