

TD2 STATISTIQUES 2 / HPC - BIG DATA 2026

Exercice 1 :

On cherche à expliquer la production photovoltaïque (P en W) par deux prédicteurs que sont les paramètres rayonnement (R en W/m²) et température de l'air (T en °C). On dispose de 30 mesures de chacune des variables, les mesures de production photovoltaïque étant issues de trois capteurs de même surface provenant de constructeurs différents nommés a, b et c (voir tableau 1 ci-dessous).

i	1	...	10	11	...	20	21	...	30
P	P ₁				...				P ₃₀
R	R ₁				...				R ₃₀
T	T ₁				...				T ₃₀
CAPT	a	...	a	b	...	b	c	...	c

On considère le modèle statistique suivant :

$$P_i = \beta_0 + \beta_1 R_i + \beta_2 T_i + e_i \quad \text{pour } i = 1, \dots, 30 \quad (\text{modèle 1})$$

Les e_i sont supposées indépendantes, identiquement distribuées suivant une loi normale centrée de variance σ^2 constante et inconnue. Les variables R et T ont été centrées.

De plus, on donne : $\sum_{i=1}^{30} T_i^2 = 10^4$; $\sum_{i=1}^{30} R_i^2 = 10^6$; $\sum_{i=1}^{30} R_i T_i = 0$

- Matriciellement le modèle s'écrit : $\mathbf{P} = \mathbf{X}\boldsymbol{\beta} + \mathbf{e}$.
 Expliciter la matrice $\mathbf{X}$ et le vecteur $\boldsymbol{\beta}$. Quelle est la dimension q du modèle ?
 Donner l'expression des estimateurs des moindres carrés $\hat{\beta}_0$, $\hat{\beta}_1$, $\hat{\beta}_2$ et expliciter la loi de chacun d'eux. Ces estimateurs sont-ils indépendants ? Donner l'expression de l'estimateur sans biais de σ^2 en fonction des P_i , T_i et R_i .
- Proposer formellement (poser les hypothèses H_0 et H_1 , la statistique de décision, sa loi sous H_0 , la règle de décision) un test de niveau α permettant de tester la significativité de l'effet de la température de l'air sur la production photovoltaïque.
- Au vu des résultats ci-dessous obtenus avec le logiciel R sur les données du problème, répondre aux questions suivantes :
 - Peut-on conclure que la température de l'air a un effet significatif sur la production photovoltaïque ? Qu'en est-il du prédicteur rayonnement global ? Justifier les réponses. Interpréter ces effets.
 - Donner une estimation de la variance de l'erreur théorique de ce modèle.
 - Interpréter le *Multiple R-Squared* fourni.

lm(formula = P ~ R + T, data)

	<i>Estimate</i>	<i>Std. Error</i>	<i>t value</i>	<i>Pr(> t)</i>
(Intercept)	80.50	2.00	40.25	1.09e-12
R	0.043	0.01	4.30	0.00021
T	-0.004	0.11	-0.036	0.972

Residual standard error: 10.95 on 27 degrees of freedom

Multiple R-squared: 0.6865

4. On cherche désormais à répondre à la question suivante :
les trois capteurs photovoltaïques ont-ils des comportements différents ?

On introduit dans notre modèle le paramètre α_{capt} pouvant prendre trois valeurs (α_a, α_b et α_c) en fonction de la modalité du facteur CAPT (voir tableau 1).
On considère donc le modèle d'analyse de covariance suivant :

$$P_i = \beta_0 + \beta_1 R_i + \beta_2 T_i + (\alpha_{\text{capt}})_i + e'_i \quad \text{pour } i = 1, \dots, 30 \quad (\text{modèle 2})$$

Les e'_i sont supposées indépendantes, identiquement distribuées suivant une loi normale centrée de variance σ'^2 constante et inconnue.

Le modèle s'écrit : $\mathbf{P} = \mathbf{Z}\boldsymbol{\beta}' + \mathbf{e}'$.

Expliciter la matrice $\mathbf{Z}$ et le vecteur $\boldsymbol{\beta}'$ du modèle 2 en imposant la contrainte d'identification notée « $\alpha_a = 0$ ». Quelle est la dimension q de ce modèle ?
Avec cette contrainte, comment interpréter les coefficients qui seront estimés ?

Les sorties R listées ci-dessous et obtenues sur les données du problème permettent-elles de répondre à la question posée ? Justifier.

lm(formula = P ~ R + T + CAPT, data)

	<i>Estimate</i>	<i>Std. Error</i>	<i>t value</i>	<i>Pr(> t)</i>
(Intercept)	73.86	1.75	42.21	1.15e-13
R	0.043	0.008	5.375	1.41e-05
T	-0.004	0.10	-0.040	0.9681
CAPT_b	3.21	1.53	2.098	0.0462
CAPT_c	0.11	1.53	0.072	0.9432

Exercice 2 :

L'électricité provenant de sources d'énergies renouvelables éolienne et photovoltaïque pose des problèmes aux gestionnaires de réseaux électriques. Par nature fluctuantes, ces productions peuvent en arriver à déstabiliser un réseau. Le gestionnaire de réseau impose donc aux producteurs d'annoncer chaque matin leur production estimée pour le lendemain.

Dans le but d'affiner l'estimation pour le lendemain de sa production photovoltaïque **PPV**, un producteur vous demande de lui fournir un modèle statistique capable de prévoir cette variable au pas horaire pour le lendemain. Il vous fournit une archive de n mesures horaires de sa production. Vous disposez également de l'archive correspondante de prévisions pour le lendemain, au pas horaire, de diverses variables issues d'un modèle météorologique et constituant de potentiels prédicteurs.

Vous disposez d'une archive des 13 variables suivantes :

PPV : productible photovoltaïque horaire mesuré à la centrale, en W

FF : force du vent prévue à 10m, en m.s^{-1}

P : pression prévue, en hPa

T : température prévue à 2m, en K

VV : vitesse verticale prévue au niveau 850 hPa, en Pa.s^{-1}

HSol : hauteur du soleil, calculée en degrés par rapport à l'horizontale

H : heure de validité de la prévision

RTH : rayonnement théorique calculé, en J.m^{-2}

FRSol : flux de rayonnement solaire descendant prévu, en J.m^{-2}

RR : cumul horaire prévu de précipitations, en kg.m^{-2}

CAPE : énergie potentielle instantanée convective prévue en $\text{m}^2.\text{s}^{-2}$

HU : humidité relative prévue, en %

N : nébulosité totale prévue en % (= fraction nuageuse de ciel), variable qualitative à 3 modalités codées : a, b et c respectivement pour les classes [0 , 30], [30 , 60] et [60 , 100].

1. Un modèle linéaire gaussien exploitant l'ensemble des prédicteurs potentiels est estimé avec R sur l'archive disponible (**modèle 1**). En analysant les sorties de R listées à la page suivante, répondre aux questions suivantes :
 - A- Quelle est la dimension du **modèle 1** ? En déduire la dimension n de l'archive d'apprentissage.
 - B- Interpréter puis commenter les résultats relatifs au prédicteur **N**.
 - C- Interpréter puis commenter les résultats relatifs aux prédicteurs **FF** et **RR**.
 - D- Quels prédicteurs conserveriez-vous ? Justifiez.
 - E- Interpréter puis commenter la valeur du *Multiple R-squared*.

modele1 = lm(PPV ~ FF+P+T+VV+HSol+H+RTH+FRSol+RR+CAPE+HU+N, data)

Coefficients:

	<i>Estimate</i>	<i>Std. Error</i>	<i>t value</i>	<i>Pr(> t)</i>
(Intercept)	-5.159e+03	1.885e+03	-2.737	0.00630
FF	-1.206e+01	5.668e+00	-2.127	0.03367
P	4.224e-02	1.701e-02	2.483	0.01319
T	3.383e+00	2.033e+00	1.664	0.09636
VV	-1.607e+01	2.889e+01	-0.556	0.57812
HSol	1.277e+01	1.549e+00	8.246	5.18e-16
H	1.737e+01	2.617e+00	6.634	5.37e-11
RTH	-2.061e-01	1.655e-01	-1.245	0.21327
FRSol	4.975e-04	2.579e-05	19.293	< 2e-16
RR	-6.972e+00	2.393e+01	-0.291	0.77088
CAPE	-2.692e-01	5.527e-02	-4.871	1.30e-06
HU	-1.648e+00	7.881e-01	-2.091	0.03675
Nb	-6.875e+01	2.719e+01	-2.528	0.01161
Nc	-1.276e+02	3.878e+01	-3.290	0.00104

Residual standard error : 320.7 on 986 degrees of freedom

Multiple R-squared : 0.875

2. Un algorithme de sélection automatique des prédicteurs autorisant les interactions d'ordre 2 est appliqué au **modèle 1**. On règle cet algorithme de façon à obtenir un modèle parcimonieux de dimension raisonnable (**modèle 2**).

En analysant les sorties de R listées ci-dessous, répondre aux questions suivantes :

A- Le **modèle 2** s'écrit matriciellement **PPV = Tβ + e**.

Donner les dimensions de **T**, **β** et **e**.

Après avoir défini **β**, expliciter le contenu de la quatrième colonne de la matrice **T**.

B- Des **modèles 1** et **2**, lequel sera d'après vous le plus performant en conditions opérationnelles ? Justifier.

modele2 = lm(PPV ~ HSol + FRSol + HSol:CAPE + FRSol:HU, data)

(syntaxe R : « X1:X2 » = produit des prédicteurs X1 et X2)


Coefficients:

	<i>Estimate</i>	<i>Std. Error</i>	<i>t value</i>	<i>Pr(> t)</i>
(Intercept)	3.945e+01	1.675e+01	2.356	0.0187
HSol	1.223e+00	1.097e-01	11.153	<2e-16
FRSol	1.064e-03	3.496e-05	30.440	<2e-16
HSol:CAPE	-5.368e-07	5.044e-08	-10.642	<2e-16
FRSol:HU	-5.300e-06	5.005e-07	-10.589	<2e-16

Residual standard error : 336.1 on 995 degrees of freedom

Multiple R-squared : 0.839

Exercice 3 :



La maquette d'un nouveau type d'éolienne est testée en soufflerie.

20 mesures de la production éolienne P en kW sont réalisées lors du test au cours duquel on fait varier la force du vent FF de 1 à 20 m/s par pas de 1 m/s.

L'allure de la réponse (graphe ci-dessus) suggère un modèle à rupture.

La réponse P de l'éolienne est modélisée en fonction de la force de vent générée dans la soufflerie de la façon suivante, pour $i = 1$ à 20 :

$$FF_i \leq 5 : P_i = \beta_0 + e_i$$

$$5 \leq FF_i \leq 15 : P_i = \beta_1 + \beta_2 FF_i + e_i$$

$$FF_i \geq 15 : P_i = \beta_3 + e_i$$

1)

On impose des contraintes traduisant la continuité de la production P aux points correspondant à $FF=5$ m/s et $FF=15$ m/s. Redéfinir alors ce modèle en fonction uniquement des paramètres β_1 et β_2 .

2)

Le modèle s'écrit matriciellement $\mathbf{P} = \mathbf{M}\boldsymbol{\beta} + \mathbf{e}$, où $\mathbf{P}$ (resp. $\mathbf{e}$) est le vecteur de $\mathbb{R}^{20}$ de composantes P_i (resp. e_i) sur la base canonique, et où $\boldsymbol{\beta}$ est le vecteur de $\mathbb{R}^2$ des paramètres du modèle. Le vecteur aléatoire $\mathbf{e}$ est supposé suivre une loi normale centrée de dimension 20 et de matrice de variance-covariance diagonale $\sigma^2 \mathbf{I}_{20}$, avec σ^2 constante et inconnue, et $\mathbf{I}_{20}$ la matrice identité.

Expliciter la design matrix $\mathbf{M}$ ainsi que le vecteur $\boldsymbol{\beta}$.

3)

Après calcul, on obtient la matrice suivante :

$$({}^t\mathbf{M}\mathbf{M})^{-1} = \frac{1}{1335} \begin{pmatrix} 487 & -41 \\ -41 & 4 \end{pmatrix}$$

Etablir les expressions des estimateurs des moindres carrés des paramètres β_1 et β_2 en fonction des données de l'archive d'apprentissage.

Donner les lois suivies par ces 2 estimateurs. Sont-ils indépendants ?

4)

Montrer qu'un estimateur de la variance théorique σ^2 du terme d'erreur s'écrit :

$$\hat{\sigma}^2 = \frac{1}{18} \left(-{}^t P M \hat{\beta} + \sum_{i=1}^{20} P_i^2 \right)$$

5)

On cherche à savoir si le paramètre théorique β_1 est susceptible d'être égal à une valeur particulière notée k . Proposer un test de niveau α permettant de conclure (définir les hypothèses à confronter, expliciter la statistique de test, la règle de décision exploitant la p-value).

6)

Un deuxième type d'éolienne est testé, **en suivant la même procédure expérimentale, indépendamment du premier test**. La réponse de cette seconde éolienne est modélisée de la même façon que la réponse de la première éolienne, avec 2 nouveaux paramètres β'_1 et β'_2 . L'estimation du second modèle à rupture traduit que pour des valeurs de force de vent supérieures à 5 m/s la deuxième éolienne semble mener à de meilleures performances que la première. On souhaite se prononcer sur la significativité de ce constat au moyen d'un test statistique.

Sur quel paramètre du modèle doit alors porter le test ?

Ce paramètre a été estimé pour chacune des éoliennes au moyen du même protocole expérimental. Pour simplifier on suppose de plus que les variances d'erreurs sont identiques pour les 2 éoliennes, ainsi que leurs estimations que l'on considérera ici comme étant égales.

Donner la loi suivie par la différence des 2 estimateurs concernés par le test.

En déduire un test de niveau α permettant de conclure sur la significativité de l'écart constaté.