

TD3 STATISTIQUES 2 / HPC - BIG DATA 2026

Exercice 1 :

On veut modéliser l'influence d'un prédicteur qualitatif (facteur) F à deux modalités nommées $i = 1$ ou 2 et d'un prédicteur quantitatif X sur une variable réponse quantitative Y . On dispose des mesures suivantes :

(i,j)	(1,1)	(1,2)	(1,3)	(1,4)	(1,5)	(2,1)	(2,2)	(2,3)	(2,4)	(2,5)
X	-2	-1	0	1	2	-2	-1	0	1	2
F	1	1	1	1	1	2	2	2	2	2
Y	y_{11}	y_{12}	y_{13}	y_{14}	y_{15}	y_{21}	y_{22}	y_{23}	y_{24}	y_{25}

On considère alors le modèle linéaire suivant :

$$y_{ij} = \mu + \alpha_i + \beta_i x_{ij} + e_{ij} \quad \text{pour } i=1 \text{ à } 2 \quad j=1, \dots, 5$$

Où y_{ij} est la variable réponse, α_i l'effet fixe relatif à la $i^{\text{ème}}$ modalité du facteur F et e_{ij} la variable erreur. Le coefficient de régression β_i prend ici deux valeurs β_1 ou β_2 en fonction de la modalité de la variable F (interaction entre X et F).

On impose la contrainte d'identification notée « $\alpha_1 + \alpha_2 = 0$ ».

Les variables aléatoires réelles e_{ij} sont supposées indépendantes et identiquement distribuées suivant la loi Normale $N(0, \sigma^2)$, σ^2 étant un paramètre inconnu.

Matriciellement le modèle s'écrit :

$$\mathbf{Y} = \mathbf{T}\boldsymbol{\beta} + \mathbf{e}$$

Où $\mathbf{Y}$ (resp. $\mathbf{e}$) est le vecteur de $\mathbb{R}^{10}$ de composantes y_{ij} (resp. e_{ij}) sur la base canonique, et où $\boldsymbol{\beta}$ est le vecteur de $\mathbb{R}^q$ des paramètres du modèle dans la base canonique.

1. Expliciter, en considérant la contrainte imposée, la matrice $\mathbf{T}$ et le vecteur $\boldsymbol{\beta}$.
Quelle est la dimension q du modèle? Expliciter la matrice ${}^t\mathbf{T}\mathbf{T}$ et calculer son inverse.
2. Exprimer les estimations des composantes du vecteur $\boldsymbol{\beta}$ en fonction des y_{ij} et x_{ij} .
Les estimateurs sont-ils indépendants ? Comment interpréter les paramètres estimés ?
3. Expliciter la loi de $\hat{\boldsymbol{\beta}}$ en fonction de $\boldsymbol{\beta}$, σ^2 et $\mathbf{T}$. En déduire la variance et l'espérance de la variable aléatoire $\hat{\beta}_1 - \hat{\beta}_2$.
4. En déduire un test de niveau α de l'hypothèse $H_0 : \beta_1 - \beta_2 = 0$ contre $H_1 : \beta_1 - \beta_2 \neq 0$
(Statistique du test, sa loi sous H_0 et la règle de décision en exploitant la p-value).

Exercice 2 : Régression logistique

On considère une variable de Bernoulli Y expliquée par un modèle de régression logistique sans terme constant et exploitant k prédicteurs. Le vecteur β de $\mathbb{R}^k$ a pour composantes les k paramètres inconnus β_j du modèle logistique et le vecteur aléatoire X de $\mathbb{R}^k$, les k prédicteurs: ${}^tX = (X_1 \dots X_k)$.

- 1) Exprimer $P(Y=1| X)$, la probabilité de succès conditionnelle aux prédicteurs, en fonction des vecteurs β et X .
- 2) On dispose d'une archive de n mesures du prédicand Y , ainsi que des mesures correspondantes des k prédicteurs. On note y_i la i ème mesure de la variable Y et X^i le vecteur de $\mathbb{R}^k$ de composantes les i èmes mesures des k prédicteurs : ${}^tX^i = (x^i_1 \dots x^i_p)$.
Les mesures y_i étant indépendantes, donner l'expression de la fonction de vraisemblance $L(\beta)$ de l'échantillon $(y_1, \dots, y_n)$ en fonction des y_i , des vecteurs X^i et du vecteur β .
- 3) Montrer que $\hat{\beta}$, estimateur du maximum de vraisemblance de β , vérifie l'équation suivante :

$$\sum_{i=1}^n y_i X^i = \sum_{i=1}^n \frac{e^{{}^t\hat{\beta} X^i}}{1 + e^{{}^t\hat{\beta} X^i}} X^i$$

Exercice 3 : Modèle linéaire généralisé poissonien

Une variable Y suit une loi de Poisson de paramètre $\lambda > 0$. On rappelle qu'on a alors $E[Y] = \lambda$ et, pour tout entier naturel y :

$$P(Y = y) = \frac{\lambda^y e^{-\lambda}}{y!}$$

- 1) Montrer que la loi de Poisson appartient à la famille exponentielle et en déduire la fonction de lien permettant d'exprimer le paramètre naturel θ de la loi en fonction de l'espérance $E[Y]$.
- 2) On cherche à expliquer la variable Y par un modèle linéaire généralisé sans terme constant et exploitant p prédicteurs quantitatifs X_j , $j=1, \dots, p$. Le vecteur $\boldsymbol{\beta}$ de $\mathbb{R}^p$ a pour composantes les p paramètres inconnus β_j du modèle statistique et le vecteur $\mathbf{X}$ de $\mathbb{R}^p$ les p prédicteurs : ${}^t\mathbf{X} = (X_1 \dots X_p)$.
Exprimer l'équation définissant le modèle linéaire généralisé poissonien.
En déduire l'expression de λ , en fonction des vecteurs $\boldsymbol{\beta}$ et $\mathbf{X}$, induite par cette modélisation.
- 3) On dispose d'une archive de n mesures du prédicteur Y ainsi que des mesures correspondantes des p prédicteurs. On note y_i la i ème mesure de la variable Y et $\mathbf{X}^i$ le vecteur de $\mathbb{R}^p$ de composantes les i èmes mesures des p prédicteurs : ${}^t\mathbf{X}^i = (x^i_1 \dots x^i_p)$.
Les mesures y_i étant indépendantes, exprimer la vraisemblance $L(\boldsymbol{\beta})$ relative à l'échantillon $(y_1, \dots, y_n)$ en fonction des y_i et des vecteurs $\mathbf{X}^i$ et $\boldsymbol{\beta}$, avec $i=1, \dots, n$.
- 4) Etablir l'équation vérifiée par $\hat{\boldsymbol{\beta}}$, l'estimateur du maximum de vraisemblance du vecteur $\boldsymbol{\beta}$.