

Adaptation statistique des prévisions d'Ozone du modèle MOCAGE

4. ANOVA : prédictors qualitatifs et contraintes d'identification

- Opérer la régression de l'ozone mesuré **O3o** par l'unique prédictor **STATION**. Analyser les sorties de la fonction **summary** et la design matrix. Comment R a-t-il géré le prédictor qualitatif **STATION** ? Interpréter alors les paramètres estimés par R.

5. ANCOVA : modèle complet et sélection automatique des prédictors

- Estimer le modèle complet d'analyse de covariance en considérant l'ensemble des prédictors potentiels, et afficher le bilan de l'estimation.
- Quels prédictors vous semblent pertinents ? Comparer avec le modèle estimé à la question 3 de la partie 1 du TP. Comment expliquer les différences constatées ?
- **Sélection automatique** : critère d'Akaike (**AIC** - Akaike Information Criterion)

L'algorithme cherche la combinaison de prédictors qui minimise l'indice **AIC**, n étant la dimension de l'archive, et j la dimension du modèle $\mathbf{Y}=\mathbf{T}\boldsymbol{\beta}+\mathbf{e}$:

$$\mathbf{AIC} = n \ln \left(\frac{\|\mathbf{Y} - \mathbf{T}\hat{\boldsymbol{\beta}}\|^2}{n} \right) + 2j$$

Quel est l'intérêt d'exploiter un tel critère ?

Charger le package MASS : **library(MASS)**

Effectuer une sélection automatique descendante (**stepAIC**).

Commenter le modèle sélectionné, quelle est sa dimension ?

- **Sélection automatique** : critère de Schwartz (**BIC** – Bayesian Information Criterion) :

On cherche le modèle qui minimise l'indice **BIC** :

$$\mathbf{BIC} = n \ln \left(\frac{\|\mathbf{Y} - \mathbf{T}\hat{\boldsymbol{\beta}}\|^2}{n} \right) + j \ln(n)$$

BIC est une variante de **AIC** qui exploite une pénalisation en $\ln(n)$ au lieu de $2j$.
 Quel va être l'impact sur le modèle sélectionné, par rapport à une sélection **AIC** ?
 Procéder à une sélection **BIC**, les variables sélectionnées sont-elles identiques
 au modèle issue d'une sélection **AIC** ?

- Estimer un modèle **BIC** testant en plus les interactions d'ordre 2 entre prédicteurs.
 Quelle est sa dimension ? Sera-t-il plus performant que les précédents modèles ?

6. Evaluation des modèles :

- Comparer sur un même graphe les observations d'ozone **O3o**, les prévisions brutes de MOCAGE **O3p** et les prévisions obtenues après post-traitements statistiques (modèle **BIC** avec interactions et régression simple exploitant le prédicteur **O3p**). Commenter.
- Coder une fonction R calculant **BIAIS** et **RMSE** d'une série de prévisions. Estimer ces scores pour les prévisions **O3p** du modèle MOCAGE et pour les modèles *simple*, **BIC** et **BIC** avec interactions. Commenter.
- Ce mode d'évaluation vous semble-t-il satisfaisant ? Quels problèmes pose-t-il ? Proposer une stratégie d'évaluation plus rigoureuse.
- Par tirage aléatoire (*sample*), créer un fichier d'apprentissage **datapp** contenant 70% des données et un fichier de test **datatest** contenant les données restantes.
- Réestimer les modèles précédents sur les données d'apprentissage. Estimer les scores sur apprentissage puis sur test (*predict*). Quelle analyse pouvez-vous faire ? Illustrer le phénomène de sur-apprentissage en estimant un modèle très complexe.
- Analyser le script **CV.R** fourni puis l'exécuter (*source*). Interpréter le graphe obtenu et conclure sur le modèle à finalement proposer.